




FASE 1

1. Fontes de Dados

Fonte	O que extrair	Uso
-------	---------------	-----

Ergast API	Resultados históricos, grid position, status DNF, pontos, pit stops	Base histórica principal
FastF1	Tempos de volta por setor, compostos de pneu, tempos de qualifying	Features de ritmo e estratégia
OpenF1 API	Dados de sessão 2025 e 2026	Validação Fase 1 e alimentação Fase 2

2. Tratamento dos Dados

Limpeza inicial

- Filtrar apenas era híbrida: 2014 em diante — mesmo corte usado no DNN lap time paper, justificado pela homogeneidade regulatória
- Remover registros com GridPosition ou FinishPosition nulos
- Criar chave primária: RaceID = piloto + temporada + round
- Remover duplicatas via RaceID

Valores ausentes

Tipo de variável	Estratégia
Numéricas contínuas (tempos de volta)	Mediana do circuito naquele ano
Categóricas (composto de pneu)	Moda da corrida
Qualifying (0,07% ausente)	Imputação KNN

Outliers

- Critério: valores acima de 3 desvios padrão da média por circuito — mesmo critério do Advanced ML paper
- Outliers legítimos como safety car e falhas mecânicas: manter com flag binária `safety_car_flag = 1`
- Outliers espúrios como erros de sensor e dados corrompidos: remover

Encoding

Variável	Método	Justificativa
Circuito, construtor	One-Hot Encoding	Sem ordem entre categorias
Composto de pneu	Label Encoding ordinal	Soft > Medium > Hard — ordem de desempenho
Piloto	Coefficiente RAPM como feature numérica	Captura habilidade de forma contínua

Normalização

- Z-score para variáveis numéricas contínuas

- MinMaxScaler para GridPosition e Laps
- XGBoost e Random Forest não exigem normalização — aplicar apenas para o baseline Ridge Regression

Balanceamento

- Problema principal é regressão — sem necessidade de balanceamento
- Se converter para classificação de pódio: aplicar SMOTE para balancear classes minoritárias (vitórias são raras)

3. Feature Engineering

Pré-computar antes do modelo

Feature criada	Fórmula	Justificativa
recent_form_5	Média ponderada posições últimas 5 corridas (pesos: 5,4,3,2,1)	Recent Form Indicator do RF+SHAP paper
recent_form_3	Média ponderada posições últimas 3 corridas	Captura forma imediata
driver_constructor_synergy	Média histórica do piloto com essa equipe específica	Driver-Constructor Synergy do RF+SHAP paper
track_complexity	Score: comprimento + curvas + elevação + incidentes históricos normalizados	Track Complexity do RF+SHAP paper
weather_impact_factor	Score: temperatura + umidade + precipitação normalizados	Weather Impact Factor do RF+SHAP paper
driver_coef_rapm	Coefficiente Ridge time-decay do piloto	Adaptado do RAPM paper
constructor_coef_rapm	Coefficiente Ridge time-decay do construtor	Adaptado do RAPM paper
driver_dnf_rate	DNFs do piloto / corridas disputadas	Perfil de agressividade — objetivo específico do TCC
constructor_dnf_rate	DNFs mecânicos / corridas do construtor	Confiabilidade do carro

4. Features Finais

Features que entram no modelo

Categoria	Feature	Descrição
Grid	grid_position	Posição de largada após qualifying
Forma recente	recent_form_5	Média ponderada últimas 5 corridas

Forma recente	recent_form_3	Média ponderada últimas 3 corridas
Piloto	driver_experience	Total de corridas disputadas na carreira
Piloto	driver_wins_total	Total de vitórias na carreira
Piloto	driver_coef_rapm	Coefficiente de habilidade via Ridge time-decay
Piloto	driver_dnf_rate	Taxa histórica de DNF do piloto
Construtor	constructor_coef_rapm	Coefficiente de competitividade via Ridge time-decay
Construtor	constructor_dnf_rate	Taxa histórica de DNF mecânico
Construtor	constructor_wins_total	Total de vitórias do construtor
Sinergia	driver_constructor_synergy	Desempenho médio do piloto com essa equipe
Circuito	circuit_type	Urbano vs permanente (binária)
Circuito	track_complexity	Score combinado de complexidade
Circuito	altitude	Altitude do circuito em metros
Pneu	tire_compound_start	Composto de largada
Pneu	avg_pit_stops_circuit	Média histórica de pit stops naquele circuito
Temporada	season_factor	Ano da corrida — captura evolução tecnológica
Clima	weather_impact_factor	Score combinado de condições climáticas
Flag	safety_car_flag	Corrida teve safety car (histórico)

Features excluídas — documentar na metodologia

Feature	Motivo
previous_position	Captura padrão trivial que quebra em 2026 — exclusão consciente e documentada
finish_position	Dado pós-corrida — data leakage
race_points	Calculado do resultado — data leakage
fastest_lap_race	Dado pós-corrida — data leakage

5. Análise de Correlação

Objetivo: identificar e remover multicolinearidade antes da modelagem

Matriz de correlação — pares a verificar

Par	Correlação esperada	Ação se > 0,85
driver_wins_total vs driver_experience	Alta	Manter driver_wins, remover experience
constructor_coef_rapm vs constructor_wins_total	Alta	Manter coef_rapm, remover wins_total
track_complexity vs circuit_length	Alta	Manter track_complexity — já incorpora length
recent_form_3 vs recent_form_5	Moderada	Manter ambas — capturam janelas diferentes
grid_position vs recent_form_5	Moderada	Manter ambas — fenômenos distintos

Correlações esperadas com o target (posição final)

Feature	Correlação esperada	Referência
grid_position	$r \approx 0,71$	Advanced ML paper
constructor_coef_rapm	$r \approx 0,60$	RAPM — carro explica 64% da variância
recent_form_5	$r \approx 0,55-0,65$	Estimativa baseada na literatura
driver_coef_rapm	$r \approx 0,35$	RAPM — piloto explica 36%
driver_dnf_rate	$r \approx 0,25-0,35$	DNF Score do RF+SHAP paper

6. PCA

Decisão: NÃO aplicar globalmente

XGBoost e Random Forest lidam bem com features correlacionadas e a interpretabilidade individual das features é uma das análises centrais do TCC. PCA global eliminaria essa interpretabilidade.

Uso restrito: aplicar PCA apenas no subconjunto de features de circuito se a correlação mostrar redundância acima de 0,85 entre circuit_length, circuit_corners, altitude e track_complexity — criando um único componente de complexidade de circuito.

Documentar essa decisão na metodologia como escolha consciente de priorizar interpretabilidade sobre redução de dimensionalidade.

7. Seleção Final de Features

```
~20 features iniciais
↓
Análise de correlação → remove redundantes (critério:  $r > 0,85$ )
↓
RFE com XGBoost → ranking de importância individual
↓
Features finais: 12-15 variáveis
↓
Validação: comparar MAE com N features vs N-1 features
(confirmar que cada feature adicionada melhora o modelo)
```

8. Divisão Treino/Teste

Walk-forward validation — obrigatório

```
Treino: 2014-2022 → Validação: 2023 → Análise de erro
Treino: 2014-2023 → Validação: 2024 → Análise de erro
Treino: 2014-2024 → Validação: 2025 → Baseline final
Treino: 2014-2025 → Drift test: 2026 → Quantificação da degradação
```

Nunca embaralhar os dados. A ordem temporal é inviolável.

Time-decay

- Fator por temporada: 0,75 como ponto de partida — valor ótimo encontrado no RAPM paper
- Otimizar o fator ideal para o seu dataset via grid-search na validação cruzada temporal
- Corridas mais antigas recebem peso exponencialmente menor

Peso da temporada 2024: 1,00
Peso da temporada 2023: 0,75
Peso da temporada 2022: 0,56
Peso da temporada 2021: 0,42
Peso da temporada 2014: 0,07

9. Algoritmos — Fase 1

Algoritmo 1: XGBoost

Aspecto	Detalhe
Tipo	Gradient Boosting — modelos em sequência
Filosofia	Reduzir viés — cada árvore corrige o erro da anterior
Regularização	L1 e L2 nativas
Vantagem	Melhor performance geral em dados tabulares
Desvantagem	Mais sensível a overfitting se mal tunado
Comportamento em drift	Mais sensível — adapta mais rápido em 2026

Algoritmo 2: Random Forest

Aspecto	Detalhe
Tipo	Bagging — modelos em paralelo independentes
Filosofia	Reduzir variância — média de muitas árvores
Regularização	Implícita pelo ensemble
Vantagem	Mais estável e robusto naturalmente
Desvantagem	Tende a ser levemente inferior em performance máxima
Comportamento em drift	Mais conservador — degrada mais devagar mas recupera mais devagar

Hiperparâmetros — otimizar via Optuna com 50 trials

Parâmetro	XGBoost	Random Forest
n_estimators	100–500	100–500
max_depth	3–10	3–15
learning_rate	0,01–0,3	N/A
subsample	0,6–1,0	N/A
max_features	N/A	sqrt, log2, 0.5
min_samples_split	N/A	2–10
reg_alpha L1	0–1	N/A
reg_lambda L2	0–1	N/A

Baseline para comparação: Ridge Regression com time-decay

Adaptado diretamente do RAPM paper. Serve como referência simples para mostrar que os modelos de árvore realmente agregam valor em relação a uma solução linear.

10. Métricas de Avaliação — Fase 1

Métrica	Meta	Referência na literatura
MAE (posições)	$\leq 2,5$	TabNet: 2,17 / RAPM: 2,3

RMSE	$\leq 3,0$	TabNet: 2,87
R ²	$\geq 0,75$	TabNet: 0,75
Kendall τ	$\geq 0,60$	RAPM: 0,625
Acurácia top-3	$\geq 70\%$	Polishchuk: 78%

11. Análises da Fase 1 para apresentar na banca

Comparativo XGBoost vs Random Forest

- MAE, RMSE, R², Kendall τ lado a lado
- Qual performa melhor em cada circuito (urbano vs permanente)
- Qual é mais estável ao longo das temporadas

Feature Importance

- Top 10 features mais importantes em cada algoritmo
- Comparar se XGBoost e Random Forest valorizam as mesmas features
- Confirmar se `grid_position` e `constructor_coef_rapm` dominam — consistente com a literatura

Quantificação do drift em 2026

- Curva de MAE das corridas de 2025 (estável) entrando em 2026 (degradação)
- Essa curva é o resultado principal da entrega parcial e o ponto de partida da Fase 2

FASE 2

1. O que muda

O pipeline de dados da Fase 1 é reaproveitado integralmente. As corridas de 2026 entram como **domínio alvo** conforme acontecem ao longo da temporada. Os dados de 2014–2025 são o **domínio fonte**.

A única adição é a camada do TrAdaBoost entre o pipeline e os algoritmos.

2. Algoritmo de Adaptação — TrAdaBoost

Lógica no contexto do TCC

Domínio fonte: corridas 2014–2025

- dados que contradizem 2026: peso DIMINUI automaticamente
- dados ainda relevantes: peso se mantém

Domínio alvo: corridas 2026 chegando uma a uma
→ dados que o modelo erra: peso AUMENTA
→ foco progressivo nos padrões da nova era regulatória

Implementação

```
python

from adapt import TrAdaBoostR2

model = TrAdaBoostR2(
    estimator=XGBRegressor(),
    n_estimators=50,
    random_state=42
)

model.fit(X_source, y_source, X_target, y_target)
```

3. Comparação Central da Fase 2

Modelo	Descrição
XGBoost estático	Modelo da Fase 1 sem adaptação — baseline de degradação
Random Forest estático	Modelo da Fase 1 sem adaptação — baseline de degradação
XGBoost + TrAdaBoost	Modelo adaptativo com reponderação regulatória
Random Forest + TrAdaBoost	Modelo adaptativo com reponderação regulatória

Essa comparação de 4 modelos responde duas perguntas simultaneamente: a adaptação funciona (estático vs adaptativo) e qual algoritmo se adapta melhor (XGBoost vs Random Forest na nova era).

4. Métrica Original do TCC

Velocidade de recuperação do MAE

Número de corridas de 2026 necessárias para que o modelo adaptativo recupere o MAE baseline de 2025.

Corridas 1–3 de 2026: $MAE \approx 4,0\text{--}5,0$ (drift máximo, ruptura regulatória)


Corridas 4–8 de 2026: $MAE \approx 3,0\text{--}3,5$ (adaptação parcial)

Corridas 9–12 de 2026: $MAE \approx 2,5\text{--}3,0$ (recuperação)

Corridas 15+ de 2026: $MAE \approx 2,0\text{--}2,5$ (estabilização próxima ao baseline)

5. Visualizações Centrais da Fase 2

Visualização 1 — Curva de recuperação do MAE



Visualização 2 — Feature importance antes e depois da transição

Comparar quais features o modelo valoriza em 2025 vs 2026 — esperado que constructor_coef_rapm mude drasticamente porque as equipes partem do zero na nova era.

Visualização 3 — Evolução dos pesos do TrAdaBoost

Mostrar quais temporadas históricas o algoritmo manteve relevantes e quais descartou — a transição 2013→2014 (introdução da era híbrida) deve ter peso próximo de zero porque é análoga à ruptura atual.

6. Métricas de Avaliação — Fase 2

Métricas padrão — mesmas da Fase 1, calculadas corrida a corrida em 2026

Métrica	Meta Fase 2	Comparação
MAE final (corridas 15+)	$\leq 2,5$	Igual ao baseline de 2025

Kendall τ final	$\geq 0,58$	Próximo ao RAPM: 0,625
Velocidade de recuperação	≤ 10 corridas	Métrica original — sem benchmark na literatura

7. Análises adicionais da Fase 2

XGBoost vs Random Forest na adaptação

A diferença de comportamento durante a transição é um resultado original. Esperado:

- XGBoost por ser sequencial e sensível a padrões recentes adapta mais rápido mas com mais variância nas primeiras corridas
- Random Forest por ser média de árvores independentes degrada mais suavemente mas recupera mais lentamente

Análise contrafactual

Usando o modelo calibrado em 2026, responder: se o regulamento de 2026 não tivesse mudado, o modelo teria continuado performando como em 2025? Isso isola o impacto da mudança regulatória do impacto de outros fatores como novos pilotos e circuitos.

Referências Bibliográficas — Fundamentação da Arquitetura do TCC

1. Predição de Resultados em Fórmula 1

- [1] POLISHCHUK, I. Predicting F1 Podiums with 78% Accuracy Using Machine Learning and Real Race Data. *Medium*, 2025. Disponível em: <https://ipolishchuk22.medium.com/predicting-f1-podiums-with-78-accuracy-using-machine-learning-and-real-race-data-0de3bcd6d2c4>
- [2] RUAN, J. et al. Formula 1 Race Winner Prediction using Random Forest and SHAP Analysis. *HAL Open Science*, 2025. Disponível em: <https://hal.science/hal-05148972v1/document>
- [3] BARRA, D. et al. Advanced Machine Learning Approaches for Formula 1 Race Performance Prediction: A Comprehensive Analysis of Championship Point Forecasting. *ResearchGate*, 2025. Disponível em: <https://www.researchgate.net/publication/394015807>
- [4] ALONSO, M. et al. The Use of Machine Learning in Predicting Formula 1 Race Outcomes. *Preprints*, 2025. Disponível em: <https://www.preprints.org/manuscript/202504.1471>
- [5] KOOPMAN, M. et al. Application of Machine Learning for Predicting Formula 1 Race Results. *Journal of Computer Sciences Institute*, 2025. Disponível em: <https://ph.pollub.pl/index.php/jcsi/article/view/8462/5371>
- [6] HEILMEIER, A. et al. A Data-Driven Analysis of Formula 1 Car Races Outcome. In: *International Conference on Intelligent Systems*, 2023. Springer. Disponível em: https://link.springer.com/chapter/10.1007/978-3-031-26438-2_11
- [7] THOMAS, D. et al. Deep Neural Network-based Lap Time Forecasting of Formula 1 Racing. *ACE Publishing*, 2024. Disponível em: <https://ace.ewapub.com/article/view/10867>
- [8] SMITH, R. et al. Data-driven Pit Stop Decision Support for Formula 1 using Deep Learning Models. *Frontiers in Artificial Intelligence*, 2025. Disponível em: <https://www.frontiersin.org/journals/artificial-intelligence/articles/10.3389/frai.2025.1673148/full>

2. Decomposição Piloto vs Construtor — Base para os Coeficientes RAPM

[9] HENDERSON, J. et al. Predicting Formula 1 Race Outcomes: Decomposing the Roles of Drivers and Constructors through Linear Modeling. *arXiv*, 2025. Disponível em: <https://arxiv.org/pdf/2508.00200>

Uso direto na arquitetura: fundamenta os coeficientes `driver_coef_rapm` e `constructor_coef_rapm`, o time-decay com fator 0,75 por temporada, e o walk-forward validation. Único paper da revisão que cita explicitamente a necessidade de recalibração para 2026.

[10] SNOEKS, M. Bayesian Analysis of Formula One Race Results: Disentangling Driver Skill and Constructor Advantage. *arXiv*, 2022. Disponível em: <https://arxiv.org/pdf/2203.08489>

Uso direto na arquitetura: confirma que o construtor explica ~88% da variância dos resultados na era híbrida — justifica o peso dado a `constructor_coef_rapm` como feature principal.

3. Impacto de Mudanças Regulatórias em Modelos Preditivos Esportivos

[11] CHEN, Z. et al. Long-Sequence LSTM Modeling for NBA Game Outcome Prediction Using a Novel Multi-Season Dataset. *arXiv*, 2025. Disponível em: <https://arxiv.org/abs/2512.08591>

Uso direto na arquitetura: demonstra empiricamente que mudanças de regras e estilo de jogo causam degradação de modelos preditivos ao longo das temporadas — paralelo direto com a ruptura regulatória de 2026 na F1.

[12] THOMAS, D. et al. Opponent State Inference Under Partial Observability: An HMM–POMDP Framework for 2026 Formula 1 Energy Strategy. *arXiv*, 2026. Disponível em: <https://arxiv.org/pdf/2603.01290>

Uso direto na arquitetura: único paper que trata tecnicamente das variáveis novas de 2026 (ERS 50/50, Override Mode, Active Aero) e formaliza explicitamente que os parâmetros do modelo precisam ser reaprendidos após a mudança regulatória.

4. Transfer Learning — Fundamentação Teórica

[13] PAN, S. J.; YANG, Q. A Survey on Transfer Learning. *IEEE Transactions on Knowledge and Data Engineering*, v. 22, n. 10, p. 1345–1359, 2010. Disponível em: <https://ieeexplore.ieee.org/document/5288526>

Uso direto na arquitetura: referência fundacional que define formalmente transfer learning, domain adaptation, covariate shift e negative transfer — vocabulário teórico central do TCC. Classifica o problema do TCC como transfer learning homogêneo, transdutivo no início e progressivamente indutivo. Fundamenta o TrAdaBoost como abordagem de instance transfer.

[14] ZHUANG, F. et al. A Comprehensive Survey on Transfer Learning. *Proceedings of the IEEE*, v. 109, n. 1, p. 43–76, 2021. Disponível em: <https://arxiv.org/pdf/1911.02685>

Uso direto na arquitetura: atualiza Pan & Yang com abordagens modernas. Fundamenta as estratégias de ponderação de instâncias (TrAdaBoost, KMM) e transformação de características usadas na Fase 2.

5. Concept Drift — Fundamentação Teórica

[15] LU, J. et al. Learning under Concept Drift: A Review. *IEEE Transactions on Knowledge and Data Engineering*, v. 31, n. 12, p. 2346–2363, 2019. Disponível em: <https://arxiv.org/abs/2004.05785>

Uso direto na arquitetura: define formalmente os tipos de drift — súbito, incremental, gradual, recorrente. A ruptura regulatória de 2026 é classificável como drift súbito por essa taxonomia, o que justifica teoricamente a escolha do TrAdaBoost sobre métodos de adaptação gradual.

[16] CERQUEIRA, V. et al. Handling Concept Drift in Global Time Series Forecasting. In: *Machine Learning and Knowledge Discovery in Databases*, 2023. Springer. Disponível em: <https://arxiv.org/pdf/2304.01512>

Uso direto na arquitetura: propõe a arquitetura de dois modelos em paralelo com pesos adaptativos ECW e GDW — alternativa mais simples ao TrAdaBoost discutida na metodologia. Os métodos propostos superam modelos estáticos especialmente em cenários de drift súbito.

[17] ZHAO, L.; SHEN, Y. Proactive Model Adaptation Against Concept Drift for Online Time Series Forecasting. *arXiv*, 2024. Disponível em: <https://arxiv.org/pdf/2412.08435>

Uso na fundamentação: apresenta o framework PROCEED para adaptação proativa antes de observar erros — discutido na metodologia como alternativa ao TrAdaBoost para as primeiras corridas de 2026.

6. Ponderação Temporal — Fundamentação do Time-Decay

[18] TAN, Q. et al. Instance-Conditional Timescales of Decay for Non-Stationary Learning. *Proceedings of AAAI*, 2024. Disponível em: <https://arxiv.org/pdf/2212.05908>

Uso direto na arquitetura: fundamenta matematicamente a estratégia de dar pesos decrescentes a dados mais antigos (time-decay) — princípio central da implementação do walk-forward com fator 0,75 por temporada.

7. Algoritmos — Fundamentação das Escolhas

[19] CHEN, T.; GUESTRIN, C. XGBoost: A Scalable Tree Boosting System. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016. Disponível em: <https://arxiv.org/abs/1603.02754>

Uso direto na arquitetura: referência original do XGBoost — algoritmo principal da Fase 1 e da Fase 2.

[20] BREIMAN, L. Random Forests. *Machine Learning*, v. 45, n. 1, p. 5–32, 2001. Disponível em: <https://link.springer.com/article/10.1023/A:1010933404324>

Uso direto na arquitetura: referência original do Random Forest — segundo algoritmo da comparação.

[21] DAI, W. et al. Boosting for Transfer Learning. In: *Proceedings of the 24th International Conference on Machine Learning*, 2007. Disponível em: <https://dl.acm.org/doi/10.1145/1273496.1273521>

Uso direto na arquitetura: referência original do TrAdaBoost — algoritmo central da Fase 2 para adaptação à ruptura regulatória de 2026.

8. Validação e Métricas — Fundamentação

[22] BERGSTRA, J.; BENGIO, Y. Random Search for Hyper-Parameter Optimization. *Journal of Machine Learning Research*, v. 13, p. 281–305, 2012.

Uso na arquitetura: fundamenta a otimização de hiperparâmetros — complementada pelo Optuna usado na implementação.

[23] AKIBA, T. et al. Optuna: A Next-generation Hyperparameter Optimization Framework. In: *Proceedings of the 25th ACM SIGKDD*, 2019. Disponível em: <https://arxiv.org/abs/1907.10902>

Uso direto na arquitetura: framework de otimização de hiperparâmetros usado no tuning do XGBoost e Random Forest com 50 trials.

Mapa de uso das referências na arquitetura

Componente da arquitetura	Referências que fundamentam
Walk-forward validation + time-decay	[9], [18]
Coeficientes RAPM (driver + constructor)	[9], [10]
Feature engineering (features específicas)	[2], [3], [6]
Features excluídas (Grupo 1 vs Grupo 2)	[2], [3], [4], [5]
XGBoost como algoritmo principal	[19], [3], [4]
Random Forest como algoritmo de comparação	[20], [2]
Justificativa do corte em 2014	[7], [9]
Drift súbito em 2026	[15], [12], [11]
TrAdaBoost na Fase 2	[13], [14], [21]
Metas de MAE e Kendall τ	[9], [4]
Acurácia de pódio 78% como benchmark	[1]