

Plano de Execução Completo — Fase 1 TCC

Versão Revisada + LightGBM como Terceiro Algoritmo

Período: 17 de maio a 12 de junho | Equipe: P1, P2, P3

[NOVO] = tarefa adicionada na revisão (não constava na versão original) **[LGB]** = tarefa adicionada para incluir LightGBM como terceiro algoritmo

Decisão: LightGBM como Terceiro Algoritmo

O cronograma original previa dois algoritmos de comparação (XGBoost e Random Forest). Com base na revisão bibliográfica — especialmente no Advanced ML paper (Barra et al., 2025) que reporta LightGBM com $R^2 = 0,999$ e MAE = 0,064 nos dados testados — optou-se por incluir LightGBM como terceiro modelo na Fase 1.

Objetivo: rodar XGBoost, Random Forest e LightGBM na Semana 2 e, ao final, selecionar os DOIS melhores algoritmos (com base em MAE, Kendall τ e custo computacional) para apresentação na banca TCC1. O terceiro algoritmo é descartado da apresentação formal mas permanece documentado no repositório.

Critério de Seleção	O que avaliar
MAE walk-forward	Menor MAE médio nos folds 2023, 2024 e 2025
Kendall τ	Maior correlação de ranking médio
Estabilidade (DP)	Menor desvio padrão entre folds
Custo computacional	Tempo de tuning — relevante para Fase 2 com TrAdaBoost
Comportamento em drift	Qual degrada mais suavemente em 2026 (análise S3)

Hipótese de trabalho: com base no benchmark do Advanced ML paper, LightGBM deve competir diretamente com XGBoost em performance máxima, enquanto Random Forest tende a ser mais conservador. Se LightGBM superar ambos no MAE, substitui XGBoost como algoritmo principal. Se ficar atrás dos dois, é descartado. A decisão é empírica.

SEMANA 1 — 17 a 23 de maio

Sem alterações na Semana 1. O pipeline de dados e feature engineering permanecem inalterados. A inclusão do LightGBM não afeta coleta, limpeza nem feature engineering.

P1 + P2 — Pipeline de Dados e Feature Engineering

(Estrutura original mantida integralmente. Ver versão anterior para detalhe dia a dia.)

Entregável interno — 23/05

- dataset_limpo.csv

- dataset_features.csv
- pipeline_dados.py
- feature_engineering.py
- **[NOVO]** rapm_ridge.py
- **[NOVO]** coef_pilotos.csv
- **[NOVO]** coef_construtores.csv
- **[NOVO]** openf1_test_aus2025.json
- **[NOVO]** mapeamento_openf1_ergast.md
- **[NOVO]** openf1_2025_clean.csv
- relatorio_correlacao.pdf

P3 — Entregável 23/05

- introducao.docx
- revisao_literatura.docx

SEMANA 2 — 24 a 30 de maio

P1 + P2 — Modelagem (XGBoost + Random Forest + LightGBM)

Segunda (24/05)

- Implementar walk-forward validation:
 - Treino 2014–2022 → Validação 2023
 - Treino 2014–2023 → Validação 2024
 - Treino 2014–2024 → Validação 2025 (dados: openf1_2025_clean.csv)
 - Treino 2014–2025 → Drift test 2026 (executado na S3, não aqui)
- **[NOVO]** Integrar openf1_2025_clean.csv como conjunto de validação 2025
 - **[NOVO]** Garantir que o pipeline de features roda corretamente sobre openf1_2025_clean.csv
 - **[NOVO]** Verificar compatibilidade de schema antes de rodar os modelos
- **[NOVO]** Otimizar fator de time-decay via grid-search
 - **[NOVO]** Testar fatores: 0,50 / 0,65 / 0,75 / 0,85 / 0,95
 - **[NOVO]** Avaliar via walk-forward em 2023–2024; selecionar fator que minimiza MAE
 - **[NOVO]** Documentar valor escolhido (o 0,75 do RAPM é ponto de partida, não fixo)
- **[NOVO]** Implementar metrics.py com todas as métricas customizadas
 - **[NOVO]** Kendall τ : correlação de rankings por corrida, média entre corridas
 - **[NOVO]** Acurácia top-3: função customizada para verificar podium previsto vs real
 - **[NOVO]** Wrapper geral: MAE, RMSE, R^2 , Kendall τ e acurácia top-3 de uma vez
- Implementar time-decay com fator otimizado (integrar ao sample_weight de XGBoost, RF e LightGBM)

[LGB] Confirmar que LightGBM aceita sample_weight nativo (sim — via `lgb.Dataset(data, weight=weights)`) e que o pipeline walk-forward passa os pesos corretamente

Terça (25/05)

- Rodar XGBoost sem tuning — verificar que o pipeline funciona do início ao fim
- Rodar Random Forest sem tuning — verificar que o pipeline funciona
- **[LGB]** Rodar LightGBM sem tuning — verificar que o pipeline walk-forward funciona com o terceiro modelo (usar parâmetros default como sanity check)

- Calcular métricas preliminares com `metricas.py` para os 3 modelos: MAE, RMSE, R^2 , Kendall τ , acurácia top-3
- Identificar e corrigir eventuais problemas no pipeline

Quarta (26/05) — Tuning Optuna: XGBoost

- Tuning Optuna — XGBoost, 50 trials:

Parâmetro XGBoost	Faixa
n_estimators	100–500
max_depth	3–10
learning_rate	0,01–0,3
subsample	0,6–1,0
reg_alpha (L1)	0–1
reg_lambda (L2)	0–1

Quinta (27/05) — Tuning Optuna: Random Forest + LightGBM

- Tuning Optuna — Random Forest, 50 trials:

Parâmetro Random Forest	Faixa
n_estimators	100–500
max_depth	3–15
max_features	sqrt, log2, 0.5
min_samples_split	2–10
min_samples_leaf	1–5

[LGB] Tuning Optuna — LightGBM, 50 trials (executar em paralelo com RF se houver capacidade computacional, ou após RF):

Parâmetro LightGBM	Faixa	Observação
n_estimators	100–500	Mesmo range do XGBoost para comparabilidade
max_depth	3–10	-1 = sem limite; testar valores fixos para controle
learning_rate	0,01–0,3	Mesmo range do XGBoost
num_leaves	20–150	Controla complexidade; substitui max_depth no LGBM
min_child_samples	5–50	Equivalente ao min_samples_leaf do RF
subsample	0,6–1,0	Bagging fraction — similar ao XGBoost
colsample_bytree	0,6–1,0	Feature fraction por árvore
reg_alpha (L1)	0–1	Regularização L1
reg_lambda (L2)	0–1	Regularização L2

[LGB] Referência: Barra et al. (2025) reporta LightGBM com MAE 0,064 — mas atenção: aquele dataset usa posição final como feature (data leakage confirmado). Para o nosso setup genuíno, espera-se MAE próximo ao XGBoost. Se ficar acima de 3,0, LightGBM é descartado.

Sexta (28/05) — Ridge baseline + Métricas finais preliminares

- **[NOVO]** Rodar Ridge Regression baseline com tuning de lambda via RidgeCV
 - **[NOVO]** Varrer alpha: faixa 0,01 a 100 em escala log com cross-validation temporal
 - **[NOVO]** Registrar o alpha ótimo — baseline forte é essencial para validar ganho dos modelos
- Calcular métricas finais preliminares dos 4 modelos com hiperparâmetros otimizados:
 - XGBoost, Random Forest, LightGBM e Ridge
 - MAE, RMSE, R², Kendall τ, acurácia top-3
 - **[NOVO]** Reportar MAE ± desvio padrão calculado sobre os folds do walk-forward
- Montar tabela comparativa completa dos 4 modelos

[LGB] Na tabela comparativa, adicionar coluna de tempo de tuning (segundos/minutos). LightGBM costuma ser mais rápido que XGBoost em datasets medianos — documentar se isso se confirma, pois impacta a viabilidade de uso na Fase 2 com TrAdaBoost iterativo.

Fim de semana (29–30/05) — Feature Selection + Decisão do terceiro algoritmo

- RFE com XGBoost: ranking de importância das features
- **[LGB]** Calcular feature importance nativa do LightGBM (gain-based) e comparar com XGBoost SHAP. LightGBM e XGBoost devem concordar nas features dominantes (grid_position, constructor_coef_rapm) — divergência significativa é sinal de alerta.
- Testar remoção das features menos importantes: verificar se MAE piora
- Definir conjunto final de 12–15 features
- **[NOVO]** Re-rodar os 3 modelos com conjunto reduzido e recalcular métricas finais definitivas
 - **[NOVO]** As métricas finais devem refletir o conjunto de features definitivo, não o completo
- Feature importance comparativa: XGBoost vs Random Forest vs LightGBM
- **[NOVO]** Salvar explicitamente feature_importance_2024.csv do fold 2024
 - **[NOVO]** Esse arquivo será comparado com a importância em 2026 na análise de drift da S3

[LGB] DECISÃO FINAL — Sábado 30/05 (deadline 23h59):

Com base nas métricas finais (MAE ± DP, Kendall τ, tempo de tuning), a equipe escolhe os DOIS algoritmos que serão apresentados na banca TCC1. O terceiro algoritmo é arquivado com comentário na documentação.

Cenário possível	Decisão
LightGBM melhor ou igual ao XGBoost em MAE	LightGBM substitui XGBoost; mantém RF como segundo
XGBoost melhor, LightGBM segundo, RF terceiro	Apresentar XGBoost + LightGBM; arquivar RF
XGBoost e RF melhores; LightGBM terceiro	Apresentar XGBoost + RF; arquivar LightGBM (retorna à versão original)
Empate técnico (DP sobreposto) entre 2 ou 3	Priorizar o de menor custo computacional para a Fase 2

- **[NOVO]** Verificar cobertura de 2025 na OpenF1 e documentar lacunas
- **[NOVO]** Alinhar equipe sobre cronograma preliminar da Fase 2 (julho–novembro)
 - **[NOVO]** P3 precisará de um esboço desse cronograma para escrever Próximos Passos na S3

Entregável interno — 30/05

Arquivo	Responsável	Observação
walk_forward.py	P1+P2	Suporta XGBoost, RF e LightGBM
[NOVO] metricas.py	P1+P2	MAE, RMSE, R ² , Kendall τ , top-3
tuning_xgboost.py	P1+P2	50 trials Optuna
tuning_randomforest.py	P1+P2	50 trials Optuna
[LGB] tuning_lightgbm.py	P1+P2	50 trials Optuna — novo arquivo
[NOVO] otimizacao_time_decay.py	P1+P2	Grid-search do fator de decay
[NOVO] otimizacao_ridge_lambda.py	P1+P2	RidgeCV baseline
tabela_metricas.csv	P1+P2	[LGB] inclui LightGBM — 4 modelos + DP
feature_importance_xgb.csv	P1+P2	Importance XGBoost
feature_importance_rf.csv	P1+P2	Importance Random Forest
[LGB] feature_importance_lgb.csv	P1+P2	Importance LightGBM — novo arquivo
[NOVO] feature_importance_2024.csv	P1+P2	Fold 2024 — referência para drift S3
[LGB] decisao_algoritmos.md	P1+P2	Justificativa da escolha dos 2 finalistas
metodologia.docx	P3	Rascunho completo

P3 — Metodologia (Semana 2)

Alteração principal: incluir LightGBM na subseção de Modelagem e preparar estrutura para a decisão dos dois algoritmos finalistas.

Quinta (27/05) — Subseção: Modelagem

- Descrever XGBoost e Random Forest com diferenças filosóficas (mantido)
- **[LGB]** Acrescentar parágrafo descrevendo LightGBM: leaf-wise tree growth (vs level-wise do XGBoost), GOSS para amostragem, EFB para features esparsas. Justificar a inclusão com Barra et al. (2025) e descrever os critérios de seleção do algoritmo finalista.
- Walk-forward validation e time-decay — incluir a otimização do fator de decay
- Ridge Regression baseline com RidgeCV — não tratar como modelo sem tuning
- Optuna para hiperparâmetros — citar os 3 modelos
- Métricas de avaliação e metas baseadas na literatura — incluir formulação do Kendall τ
- **[LGB]** Adicionar nota metodológica: 'Três algoritmos foram avaliados empiricamente. Os dois com melhor desempenho no walk-forward foram selecionados para apresentação, garantindo que a escolha seja orientada por dados e não por preferência a priori.'

SEMANA 3 — 31 de maio a 5 de junho

As três trabalham em paralelo — o código está pronto e cada uma tem responsabilidade independente. A partir desta semana, só os DOIS algoritmos finalistas são analisados em profundidade. O terceiro permanece nos arquivos mas não gera visualizações adicionais.

P1 — Documentação do Código

Segunda (31/05)

- **[NOVO]** Criar script de atualização incremental `update_openf1_2026.py`
- Documentar `pipeline_dados.py`: docstring em cada função, comentários de cada decisão de limpeza

Terça (01/06)

- Documentar `feature_engineering.py`: fórmula de cada feature, referência ao artigo de origem
- **[NOVO]** Documentar `rapm_ridge.py`: lógica da Ridge iterativa, time-decay, opção LOESS
- **[LGB]** Documentar `tuning_lightgbm.py` e `feature_importance_lgb.csv` com comentários sobre as diferenças de hiperparâmetros em relação ao XGBoost (especialmente `num_leaves` vs `max_depth`)

Quarta (02/06)

- Criar notebook Jupyter de demonstração: pipeline completo dos DOIS algoritmos finalistas, resultados reais, visualizações inline, seed fixo

Quinta (03/06)

- Criar README completo: instruções de instalação, como reproduzir resultados, descrição de cada arquivo, seção sobre `update_openf1_2026.py`
- **[LGB]** Incluir seção no README: 'Avaliação de algoritmos' explicando que 3 modelos foram testados e como reproduzir a comparação completa, mesmo que apenas 2 sejam apresentados na banca

Sexta (04–05/06)

- Revisão cruzada: ler seção de Resultados do P3 e verificar se os números batem com o código
- Ajustes finais na documentação

P2 — Análises Finais e Visualizações

Segunda (31/05)

- **[NOVO]** Extrair corridas de 2026 disponíveis via OpenF1 (rodar `update_openf1_2026.py`)
- **[NOVO]** Aplicar pipeline de limpeza e features — salvar em `openf1_2026_available.csv`
- Aplicar os DOIS modelos finalistas treinados em 2014–2025 nas corridas de 2026 (drift test)
- **[LGB]** Se LightGBM for um dos finalistas: incluí-lo nas curvas de drift. Se for o terceiro descartado: documentar MAE pontual de 2026 apenas na tabela de arquivos (sem visualização dedicada)
- Construir curva de degradação: MAE por corrida de 2025 entrando em 2026

Terça (01/06)

- Análise de erro por tipo de circuito: MAE em urbanos vs permanentes para os 2 finalistas
- Análise de erro por posição no grid

Quarta (02/06)

- Feature importance antes e depois da transição regulatória:
 - Usar `feature_importance_2024.csv` como referência do 'antes'
 - Calcular feature importance nas primeiras corridas de 2026 como referência do 'depois'
 - Comparar: quais features mudam mais entre as duas eras (esperado: `constructor_coef_rapm`)

Quinta (03/06)

- Comparar degradação dos DOIS finalistas em 2026: qual degrada mais rápido? qual tem maior variância?
- **[NOVO]** Análise contrafactual: projetar MAE esperado sem drift e sobrepor à curva real
- **[NOVO]** Atualizar openf1_2026_available.csv antes de gerar gráficos finais

Sexta (04–05/06)

- Finalizar todas as visualizações em qualidade de publicação:
 - Curva de MAE ao longo de 2025
 - Curva de drift entrando em 2026 com linha contrafactual sobreposta
 - Feature importance comparativa dos 2 finalistas (2024 vs primeiras corridas de 2026)
 - Tabela de métricas final com desvio padrão entre folds (inclui LightGBM mesmo se descartado)

P3 — Resultados Parciais + Próximos Passos + Integração

Segunda (31/05)

- Resultados — Comparativo de modelos:
 - Tabela com os 4 modelos: XGBoost, RF, LightGBM e Ridge (com desvio padrão)
 - **[LGB]** Incluir parágrafo explicando o critério de seleção dos 2 finalistas e por que o terceiro foi descartado
 - Discussão: resultados consistentes com a literatura? Comparar MAE com TabNet (2,17) e RAPM (2,3)

Terça (01/06)

- Resultados — Feature importance: quais variáveis dominam em cada algoritmo finalista

Quarta (02/06)

- Resultados — Quantificação do drift em 2026 + Análise contrafactual

Quinta (03/06)

- Próximos Passos: arquitetura Fase 2 com TrAdaBoost, métrica de velocidade de recuperação, cronograma julho–novembro

Sexta (04–05/06)

- Integrar todos os documentos em arquivo único ABNT (capa, sumário, todas as seções)

Entregável interno — 05/06

Arquivo	Responsável	Observação
codigo_fase1/ completo e documentado	P1	Inclui tuning_lightgbm.py
notebook_demonstracao.ipynb	P1	Dois algoritmos finalistas
README.md	P1	Seção sobre avaliação dos 3 algoritmos
[NOVO] update_openf1_2026.py	P1	Script incremental
graficos/ todas as visualizações	P2	Qualidade de publicação
analise_drift_2026.csv	P2	Dois algoritmos finalistas
analise_por_circuito.csv	P2	
[NOVO] openf1_2026_available.csv	P2	
[NOVO] analise_contrafactual.csv	P2	

Arquivo	Responsável	Observação
[LGB] tabela_comparativa_3modelos.csv	P2	Todos os 3 + Ridge, mesmo se 1 descartado
tcc1_fase1_completo.docx	P3	Versão quase final

SEMANA DE FOLGA — 6 a 12 de junho

Revisão cruzada obrigatória: ninguém entrega sem que outra pessoa tenha lido. Inconsistências entre código e texto são o erro mais comum em TCCs.

Métricas de Sucesso da Fase 1

Métrica	Meta	Referência
MAE (posições)	$\leq 2,5$	TabNet: 2,17 / RAPM: 2,3
RMSE	$\leq 3,0$	TabNet: 2,87
R ²	$\geq 0,75$	TabNet: 0,75
Kendall τ	$\geq 0,60$	RAPM: 0,625
Acurácia top-3	$\geq 70\%$	Polishchuk: 78%

Pontos de Atenção

Custo computacional do tuning triplo

Rodar Optuna com 50 trials para 3 modelos pode levar tempo significativo. Se necessário, reduzir para 30 trials no LightGBM (que é intrinsecamente mais rápido) e manter 50 no XGBoost e RF. Prioridade: qualidade do tuning dos dois melhores candidatos.

LightGBM e sample_weight no walk-forward

Confirmar na segunda da S2 que lgb.Dataset aceita os pesos de time-decay corretamente e que o fold-by-fold não reusa o dataset object (bug comum). Testar com um fold antes de rodar os 3 completos.

Feature importance LightGBM vs XGBoost

LightGBM calcula importance por 'gain' (padrão), 'split' e 'cover'. Para comparabilidade com XGBoost SHAP, usar 'gain'. Se houver divergência grande nas features top-5, investigar antes de concluir a seleção final de features.

A decisão dos finalistas é irrevogável após 30/05

A partir da Semana 3, P2 gera visualizações e P3 escreve os resultados com base nos 2 algoritmos escolhidos. Mudança tardia obriga refazer gráficos e texto. Deadline 23h59 de sábado 30/05 é rígido.

Dependência crítica — OpenF1 e coeficientes RAPM (inalterada)

O mapeamento da OpenF1 na segunda da S1 é pré-requisito para a extração de 2025 no fim de semana e para a validação do walk-forward na semana seguinte. O rapm_ridge.py não é uma feature em uma linha — reservar a quinta inteira da S1.

Fator de time-decay deve ser otimizado (inalterado)

O valor 0,75 vem do RAPM paper e é ponto de partida. O grid-search na segunda da S2 pode encontrar um fator diferente para este dataset. Usar 0,75 sem verificar é uma decisão metodológica indefensável na banca.

Se o MAE ficar acima de 2,5

Não é catástrofe. Documentar honestamente, comparar com os benchmarks do Grupo 2 e usar como motivação adicional para a Fase 2. Um MAE de 3,0 ainda está dentro do estado da arte real de previsão genuína em F1.